FIAP · Global Solution 2026.2 · CitizenTech
Engenharia de Software · 4º ano

Boca de Lobo

Componente Dados: pipeline Airflow + Lakehouse Bronze/Prata/Ouro no Databricks

Big Data Architecture & Data Integration

Segurança e emergências (enchentes) · ODS 11, 13 e 3

Repositório: https://github.com/FelipeVoidela/GS2-2026-Big-Data-Architecture

01 · Integrantes

Nome completo	RM
Açussena Macedo Mautone	552568
Felipe Heilmann Marques	551026
Felipe Voidela Toledo	98595
Carlos Eduardo Caramante Ribeiro	552159
Ian Cancian Nachtergaele	98387

02 · O produto em uma frase e as perguntas que o MVP responde

Boca de Lobo: antes de cada temporal, um robô inspeciona as bocas de lobo do bairro; quando a previsão indica chuva forte, o sistema cruza os bueiros entupidos com as áreas de risco e avisa a equipe de limpeza (rota priorizada) e o morador (onde não passar).

Cidadão: morador de região que alaga todo verão, principalmente em áreas baixas e periféricas de São Paulo.

Perguntas que o MVP responde com os dados deste pipeline:

#	Pergunta	Quem pergunta	Tabela/consulta
1	Quantos bueiros entupidos estão em área de risco com chuva forte prevista para as próximas 24 h, e quantas pessoas moram ali? (IMPACTO)	Defesa Civil, prefeitura	Consulta 1
2	Quais bueiros a equipe deve limpar primeiro hoje?	equipe de limpeza, bot RPA	Consulta 2 / ouro_vw_rota_limpeza
3	Quais subprefeituras concentram bueiros críticos em área de risco?	prefeitura, concessionária	Consulta 3
4	A situação piorou ou melhorou de uma coleta para a outra?	gestão do contrato	Consulta 4
5	Quanto o cidadão espera quando pede limpeza no SP156, e o robô confirma o problema?	cidadão, ouvidoria	Consulta 5
6	Tem bueiro entupido perto de mim? Devo evitar a minha rua hoje?	morador	ouro_vw_mapa_cidadao (tela do MVP)

03 · Diagrama do fluxo de dados, da fonte ao MVP

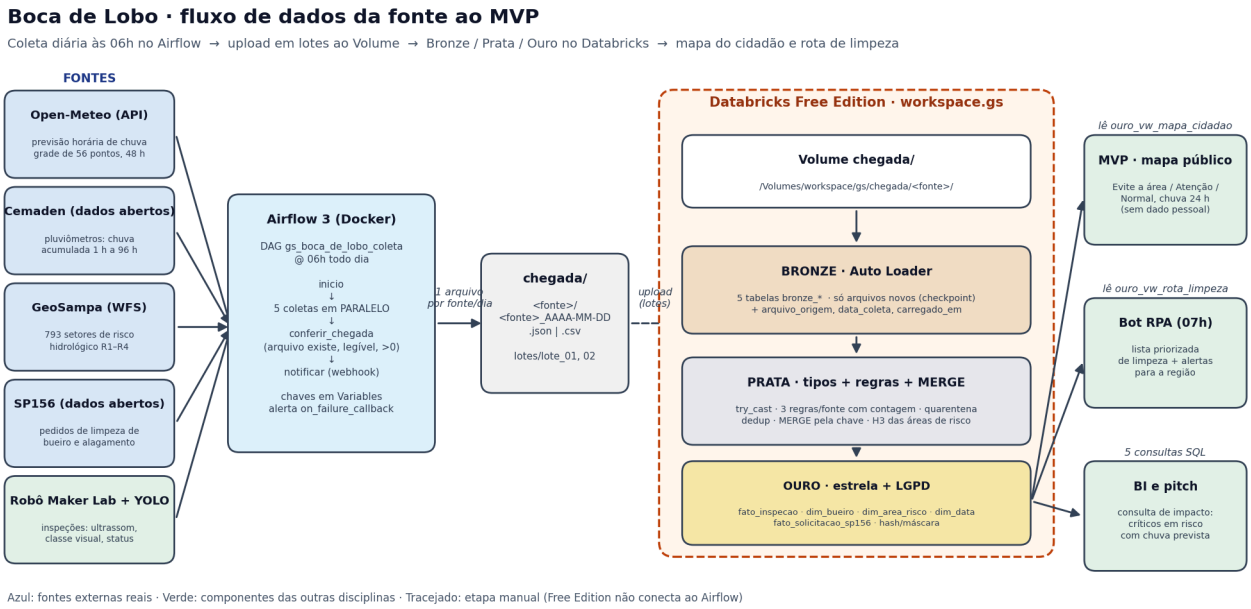


Figura 1 - Fluxo de dados: fontes → Airflow → chegada/ → Volume → Bronze → Prata → Ouro → MVP, RPA e BI

O Databricks Free Edition não se conecta ao Airflow: os arquivos de chegada/ sobem ao Volume pela interface, em lotes de dias de coleta diferentes (seta tracejada).

04 · Tabela de fontes

Fonte	Origem	Formato	Frequência	Volume por coleta
Open-Meteo (API externa)	api.open-meteo.com/v1/forecast	JSON (array)	diária 06h	56 pontos × 48 h
Cemaden (dado aberto externo)	resources.cemaden.gov.br · getJson2.php?uf=SP	JSON (array)	diária 06h	724 estações (79 na capital)
GeoSampa (WFS da prefeitura)	camada geoportal:risco_hidrologico	GeoJSON → JSON Lines	diária 06h	793 setores de risco
SP156 (dado aberto)	dados.prefeitura.sp.gov.br (CKAN, trimestre mais recente)	CSV	diária 06h (cache por trimestre)	10.758 pedidos de drenagem
Robô Maker Lab + YOLO (simulado)	dags/boca_de_lobo/simulador_robo.py	JSON Lines	diária 06h	≈200 inspeções

Dado simulado, com justificativa: o robô e o YOLO ainda estão em construção nas disciplinas de Maker Lab e Visão. O simulador produz exatamente o JSON que o robô vai enviar, sobre 300 pontos reais (endereços de pedidos de limpeza de boca de lobo no SP156, 60% perto de área de risco), com acúmulo de lixo realista e ~6% de defeitos propositais para testar as regras da Prata. É determinístico por data (coleta idempotente) e usa operadores fictícios.

05 · Requisitos 01 a 09

Requisito 01 · Fontes de dados do problema

Cinco fontes, quatro delas externas e reais (Open-Meteo, Cemaden, GeoSampa e SP156) e uma interna (robô). Todas falam do mesmo problema: chuva prevista e observada, onde alaga, onde o cidadão já reclamou e qual bueiro está entupido. A conferência do Airflow registra quantos registros chegaram de cada uma:



Figura 2 - Log da tarefa conferir_chegada com os registros recebidos de cada fonte em 07/11/2026

Requisito 02 · DAG agendado gravando em chegada/

DAG gs_boca_de_lobo_coleta, agendado para 06h todo dia (cron 0 6 * * *, fuso de São Paulo), uma hora antes do bot de RPA. Cada tarefa grava um arquivo por coleta em chegada/<fonte>/<fonte>_AAAA-MM-DD.<ext>, de forma atômica (.tmp + rename) e idempotente (rodar de novo sobrescreve o mesmo arquivo).

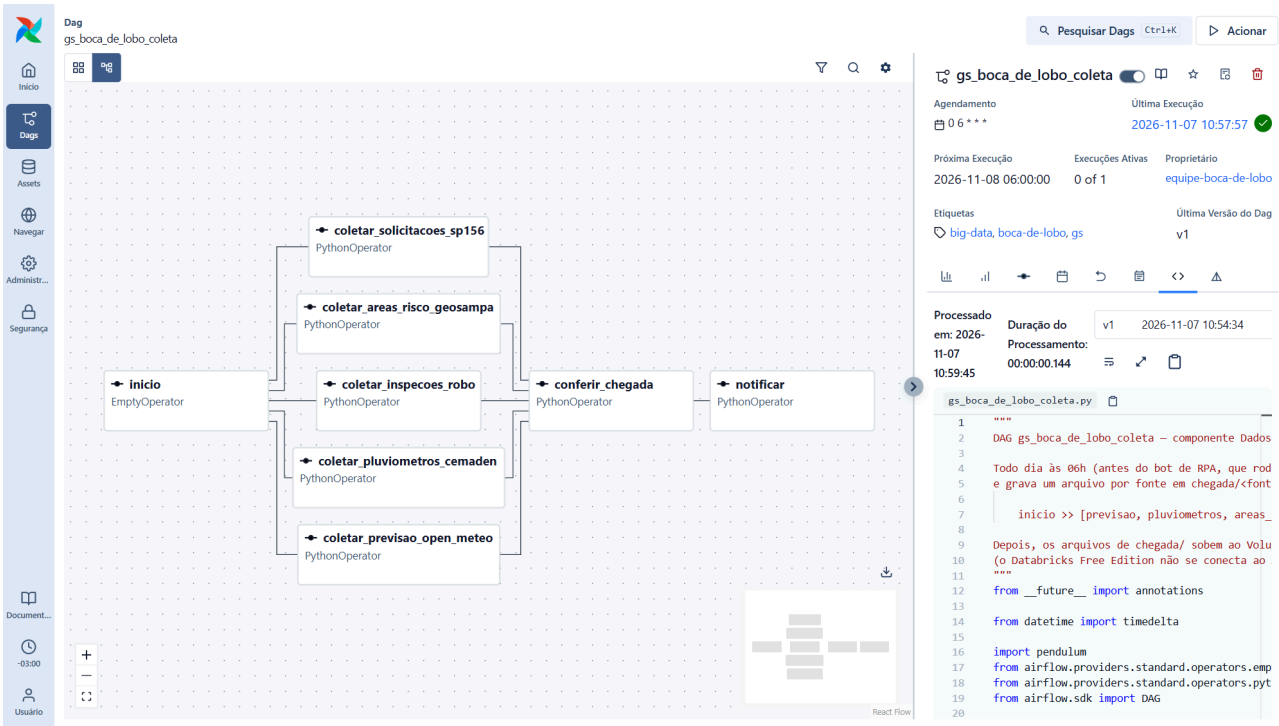


Figura 3 - Código do DAG no Airflow: agendamento, tarefas e dependências

chegada/
previsao/previsao_2026-11-07.json previsao/previsao_2026-11-08.json
pluviometros/pluviometros_2026-11-07.json ...
areas_risco/areas_risco_2026-11-07.json ...
sp156/sp156_2026-11-07.csv ...
inspecoes/inspecoes_2026-11-07.json ...

Requisito 03 · Paralelismo, verificação e chaves fora do código

inicio >> [5 coletas em paralelo] >> conferir_chegada >> notificar. A conferência falha se algum arquivo do dia não existe, está vazio ou ilegível. Cada coleta tem 2 novas tentativas e on_failure_callback, que avisa por webhook. A URL do webhook e a chave do Open-Meteo (plano comercial) ficam em Variables do Airflow (gs_alerta_webhook_url, gs_open_meteo_apikey), nunca no código. A tarefa notificar falha de propósito se a conferência não passou, para a execução ficar vermelha: num sistema de emergência, a falha silenciosa é o pior cenário.

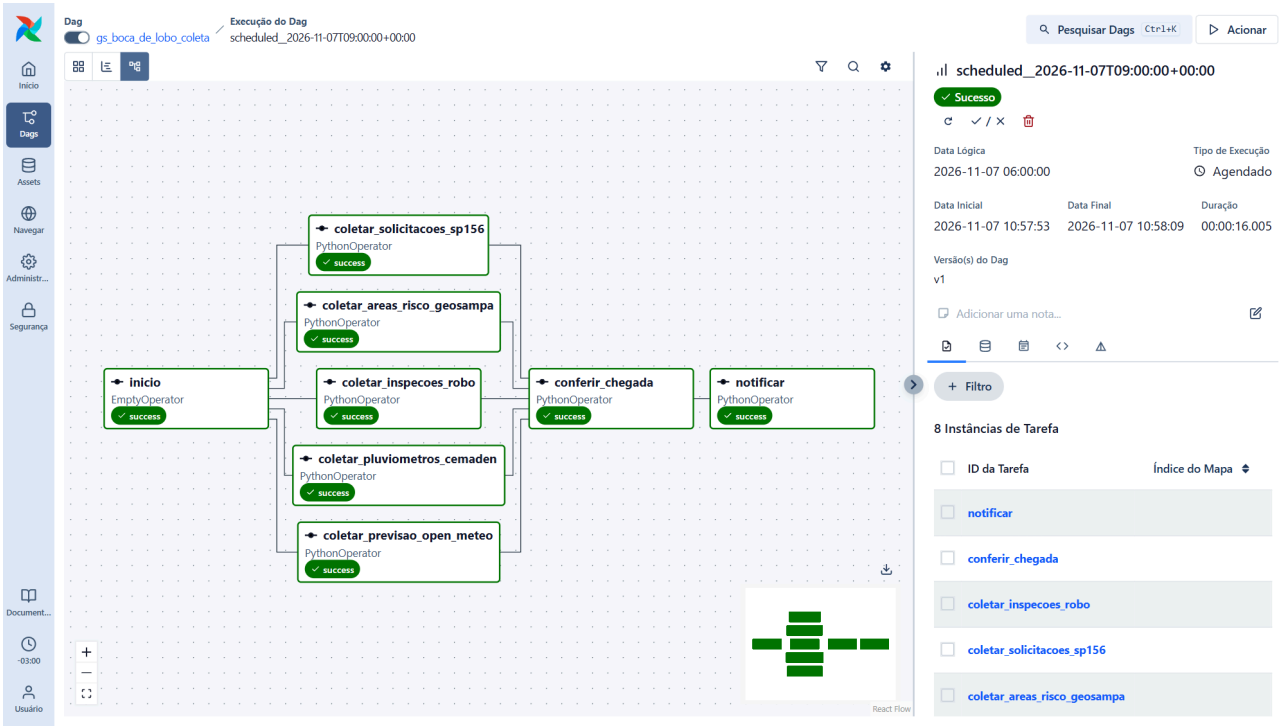


Figura 4 - Visão Graph: 5 coletas em paralelo, conferência e notificação, todas com sucesso



Figura 5 - Log da tarefa notificar (sem webhook configurado, a mensagem vai para o log)

> ***[INSERIR PRINT] Admin > Variables: gs_alerta_webhook_url (e gs_open_meteo_apikey, se usada) cadastradas, valores mascarados***

Figura 6 - (legenda) Admin > Variables: gs_alerta_webhook_url (e gs_open_meteo_apikey, se usada) cadastradas, valores mascarados

Requisito 04 · Dois lotes enviados ao Volume

scripts/montar_lotes.py separa os arquivos por dia de coleta: lote_01 = execução agendada de 07/11 (06h), lote_02 = execução agendada de 08/11 (06h). Cada lote foi enviado pela interface do Databricks para /Volumes/workspace/gs/chegada/<fonte>/.

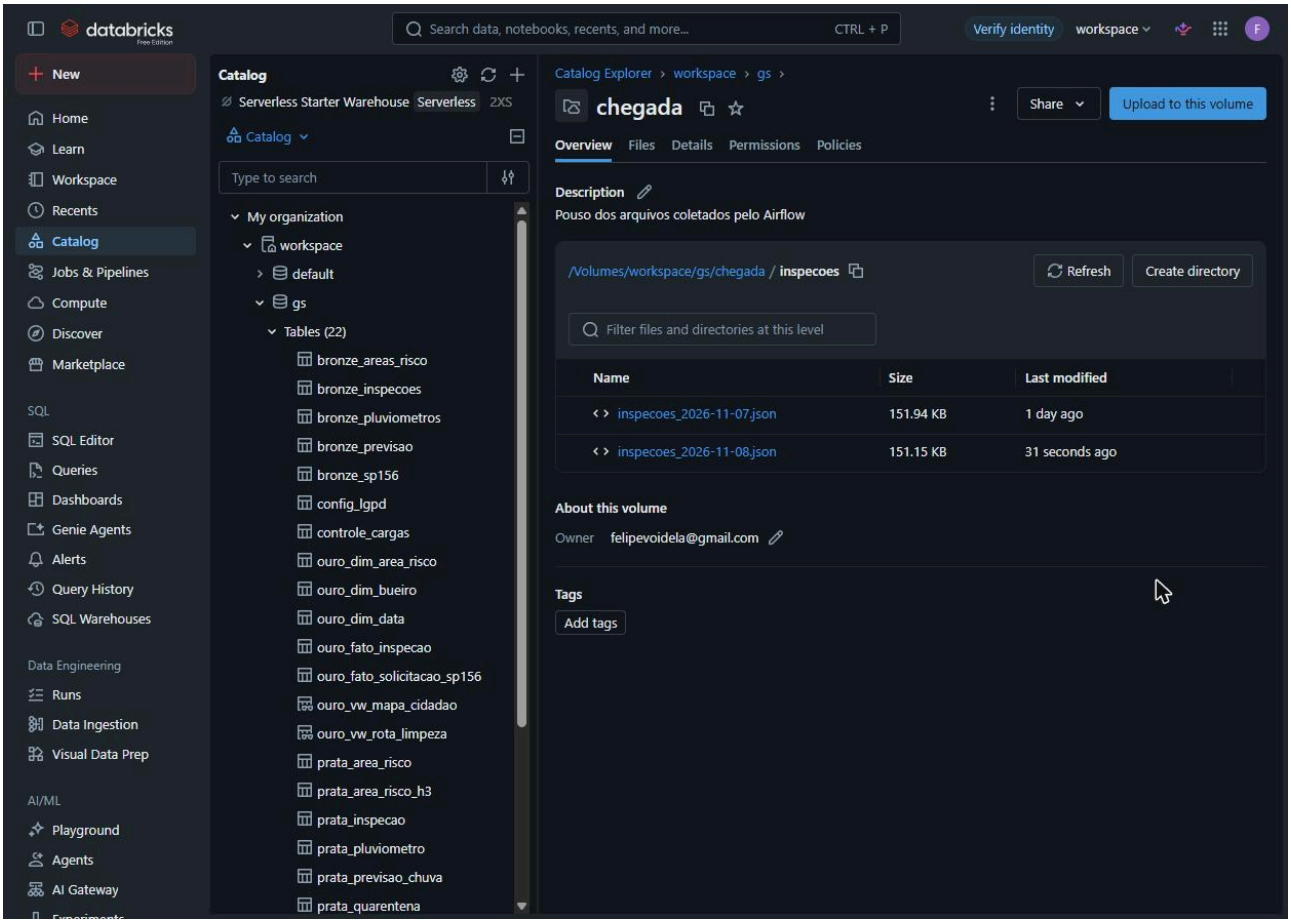


Figura 7 - Volume workspace.gs.chegada, pasta inspecoes: um arquivo por dia de coleta, enviado pela interface

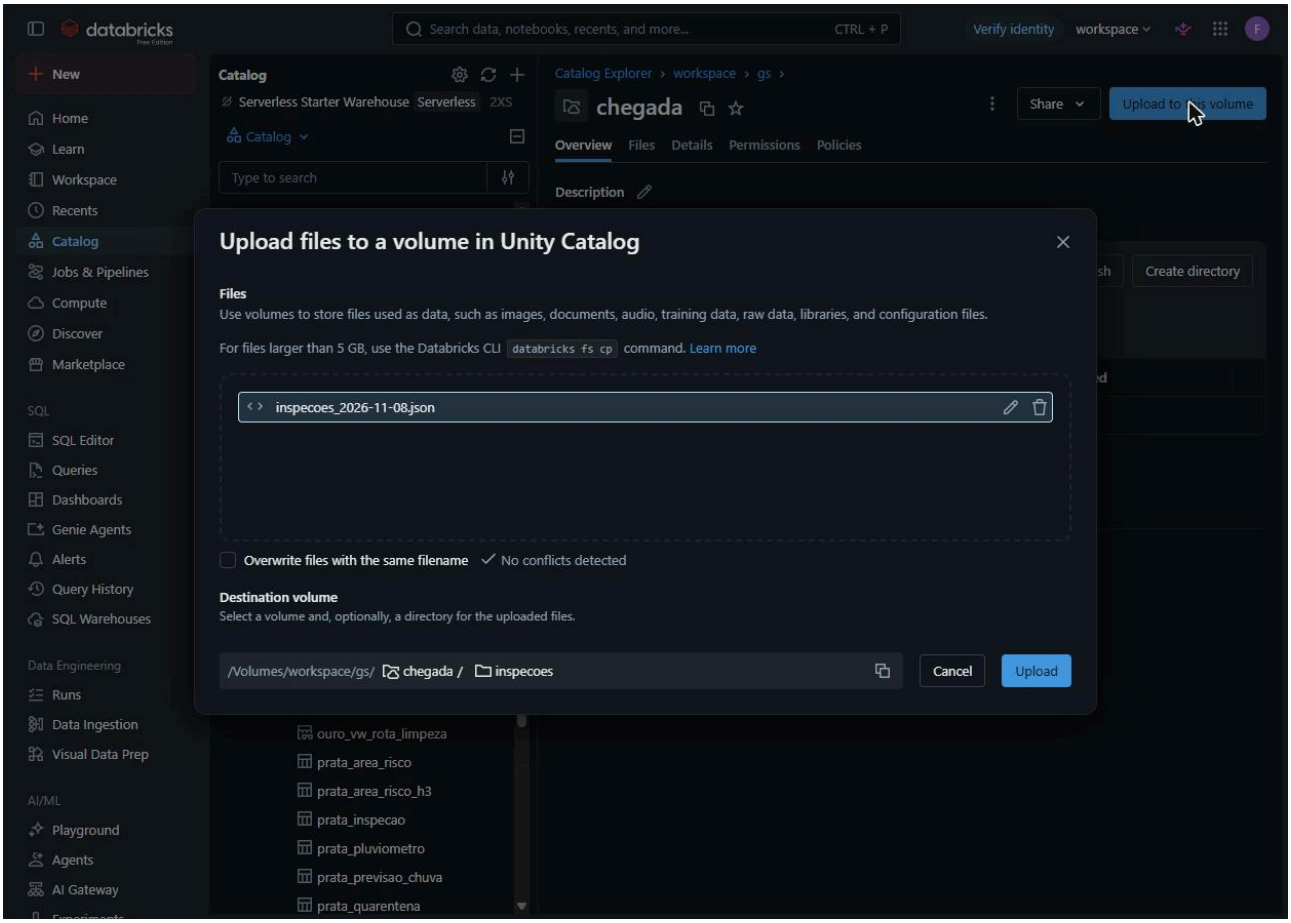


Figura 8 - Envio do 2º lote pela interface (Upload to this volume)

Requisito 05 · Bronze incremental e sem duplicação

Auto Loader (cloudFiles) com checkpoint por fonte e trigger(availableNow=True). Tudo é lido como texto (inferColumnTypes = false) e cada linha ganha arquivo_origem, data_coleta e carregado_em. No 2º lote só os arquivos novos entram; rodar de novo sem arquivo novo insere 0 linhas. As contagens estão no item 07.

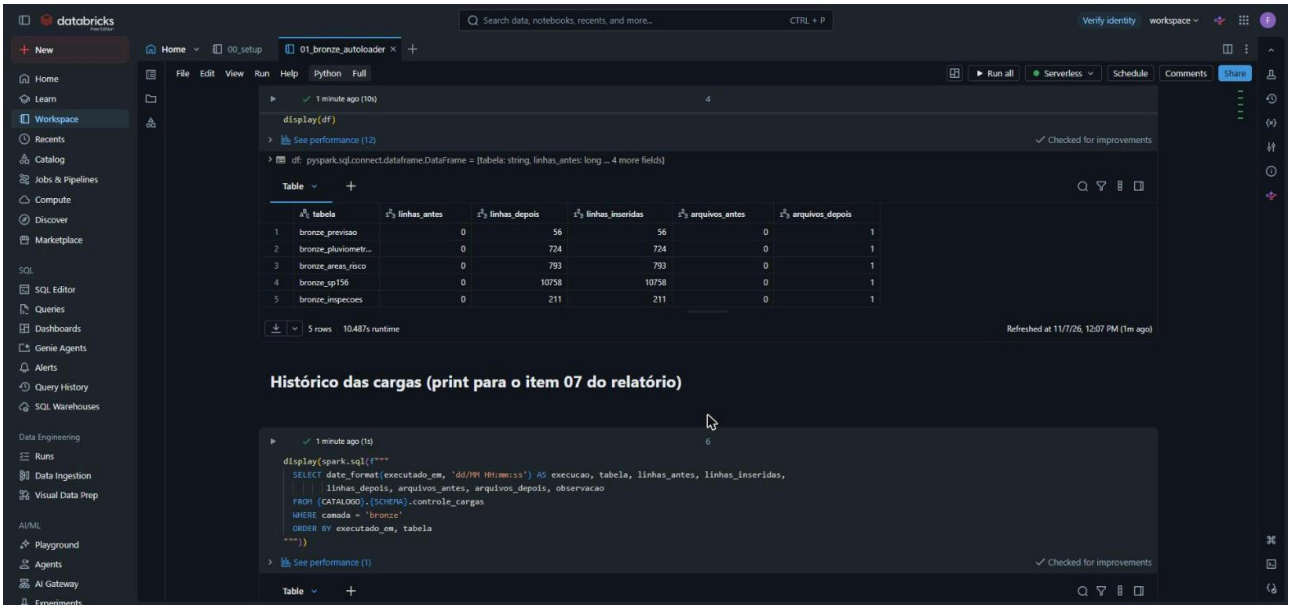


Figura 9 - Notebook 01 depois do lote 1: o Auto Loader carregou 1 arquivo por fonte (linhas_antes = 0)

Requisito 06 · Prata: tratamento, MERGE e regras de qualidade

Cada fonte é lida da Bronze em streaming (só o que é novo) e cada micro-lote passa por: tipagem com try_cast/try_to_timestamp (o serverless roda em modo ANSI), 3 regras de qualidade com contagem por regra, quarentena dos registros barrados, deduplicação pela chave e MERGE INTO pela chave.

Tabela	Regra	O que barra
prata_inspecao	INSP_01_ultrassom_valido	profundidade livre nula, negativa ou maior que a nominal
prata_inspecao	INSP_02_visao_valida	classe do YOLO desconhecida ou confiança fora de 0–1
prata_inspecao	INSP_03_gps_valido	coordenada fora de SP (GPS 0,0)
prata_pluviometro	PLUV_01/02/03	leitura '-', estação parada há mais de 2 dias, acumulados incoerentes
prata_solicitacao_sp156	SP156_01/02/03	sem coordenada, data de abertura inválida, finalização antes da abertura
prata_previsao_chuva	PREV_01/02/03	precipitação nula ou absurda, probabilidade fora de 0–100, ponto fora de SP
prata_area_risco	AREA_01/02/03	grau fora de R1–R4, polígono ausente, moradias negativas
todas	DEDUP	registros repetidos pela chave no lote (ex.: reenvio do robô)

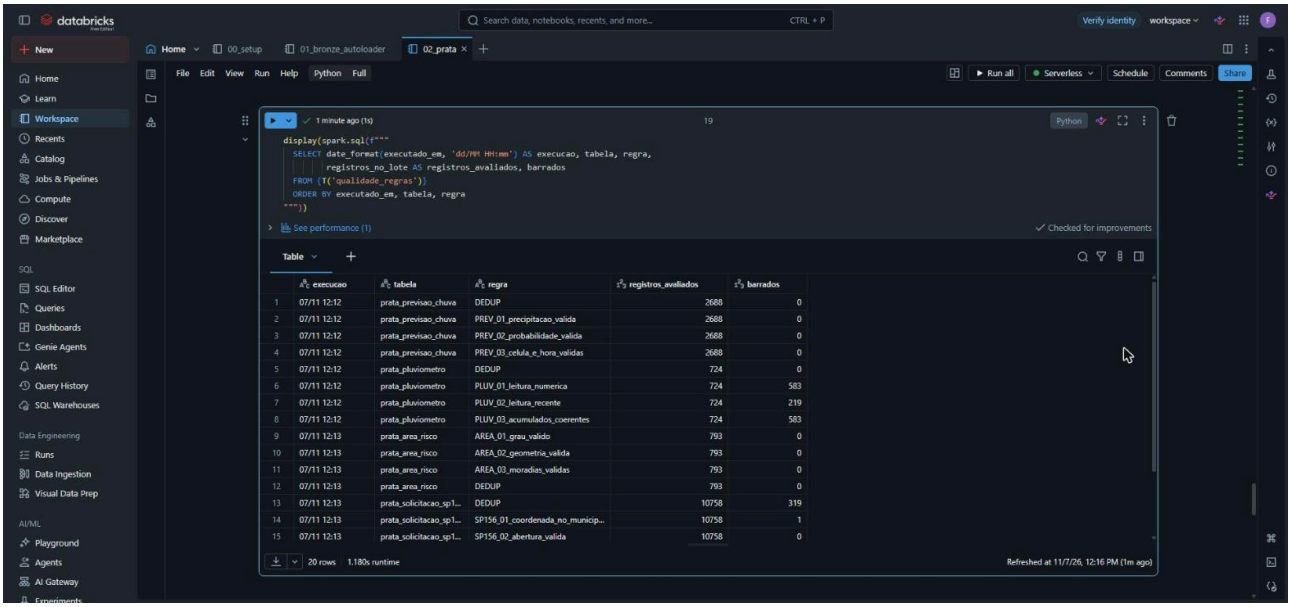
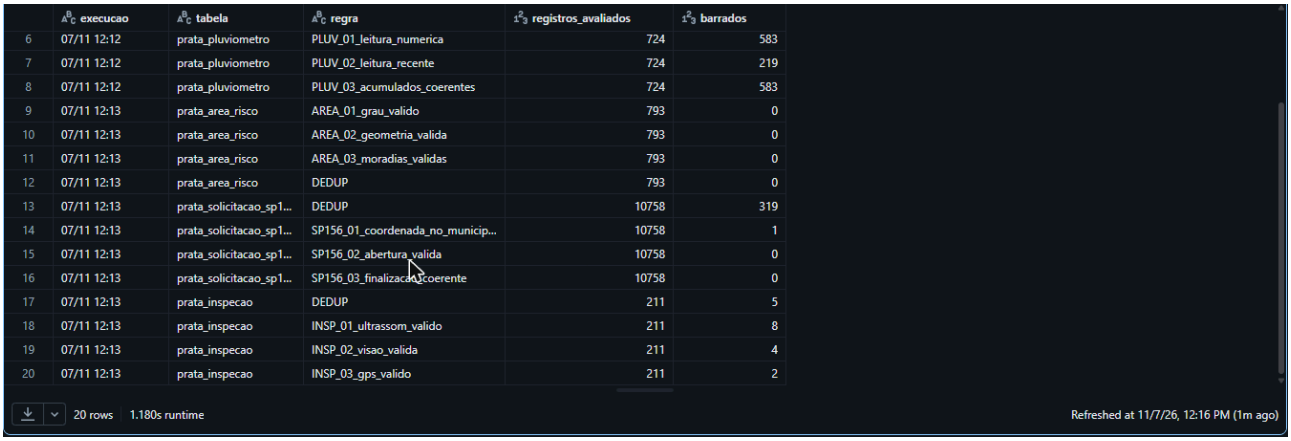


Figura 10 - Notebook 02: total barrado por regra de qualidade em cada execução (parte 1)



	execucao	tabela	regra	registros_avaliados	barrados
6	07/11 12:12	prata_pluviometro	PLUV_01_leitura_numerica	724	583
7	07/11 12:12	prata_pluviometro	PLUV_02_leitura_recente	724	219
8	07/11 12:12	prata_pluviometro	PLUV_03_acumulados_coerentes	724	583
9	07/11 12:13	prata_area_risco	AREA_01_grau_valido	793	0
10	07/11 12:13	prata_area_risco	AREA_02_geometria_valida	793	0
11	07/11 12:13	prata_area_risco	AREA_03_moradias_validas	793	0
12	07/11 12:13	prata_area_risco	DEDUP	793	0
13	07/11 12:13	prata_solicitacao_sp1...	DEDUP	10758	319
14	07/11 12:13	prata_solicitacao_sp1...	SP156_01_coordenada_no_municip...	10758	1
15	07/11 12:13	prata_solicitacao_sp1...	SP156_02_abertura_valida	10758	0
16	07/11 12:13	prata_solicitacao_sp1...	SP156_03_finalizacao_coerente	10758	0
17	07/11 12:13	prata_inspecao	DEDUP	211	5
18	07/11 12:13	prata_inspecao	INSP_01_ultrassom_valido	211	8
19	07/11 12:13	prata_inspecao	INSP_02_visao_valida	211	4
20	07/11 12:13	prata_inspecao	INSP_03_gps_valido	211	2

20 rows 1.180s runtime
Refreshed at 11/7/26, 12:16 PM (1m ago)

Figura 11 - Notebook 02: total barrado por regra de qualidade em cada execução (parte 2)

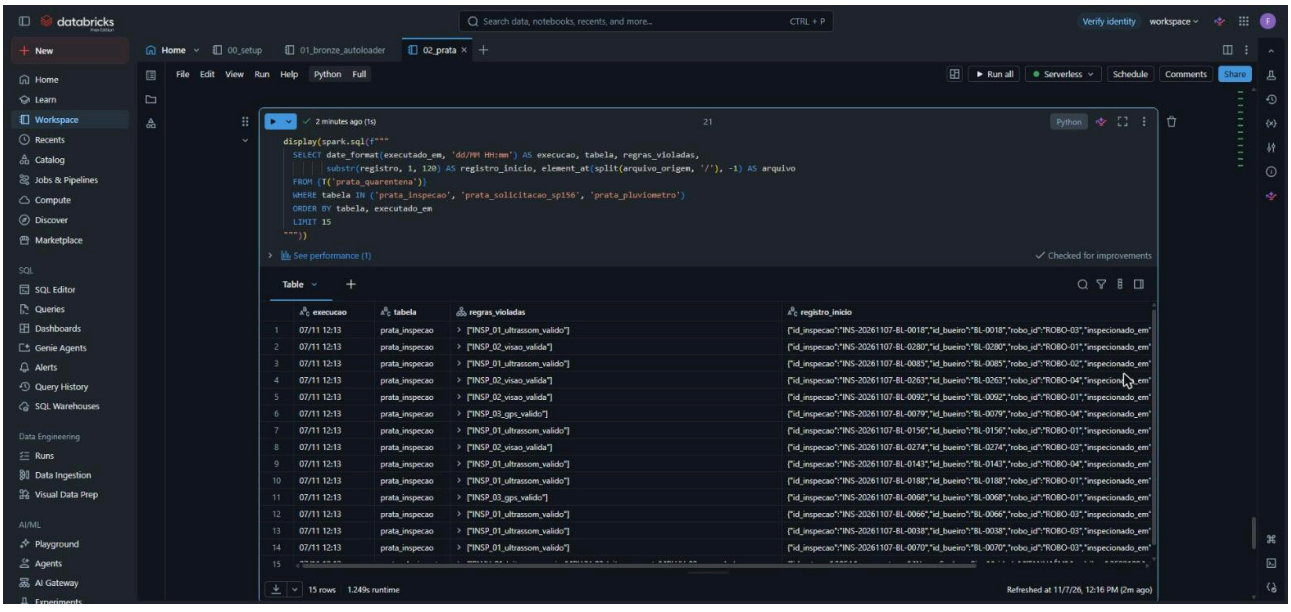


Figura 12 - prata_quarentena: o registro barrado inteiro e as regras que ele violou

Requisito 07 · Ouro dimensional e 5 consultas

Modelo estrela: ouro_fato_inspecao (1 bueiro × 1 dia) com ouro_dim_bueiro, ouro_dim_area_risco e ouro_dim_data; e um segundo fato, ouro_fato_solicitacao_sp156. O cruzamento bueiro × área de risco usa índice H3 (resolução 10, ~66 m, com vizinhança de 1 anel): vira um JOIN por número inteiro, sem cálculo geométrico pesado. O score_prioridade (0–100) soma status do robô (até 50), grau da área de risco (até 30), chuva prevista (até 15) e pedidos do SP156 por perto (até 5). As 5 consultas estão no item 08.

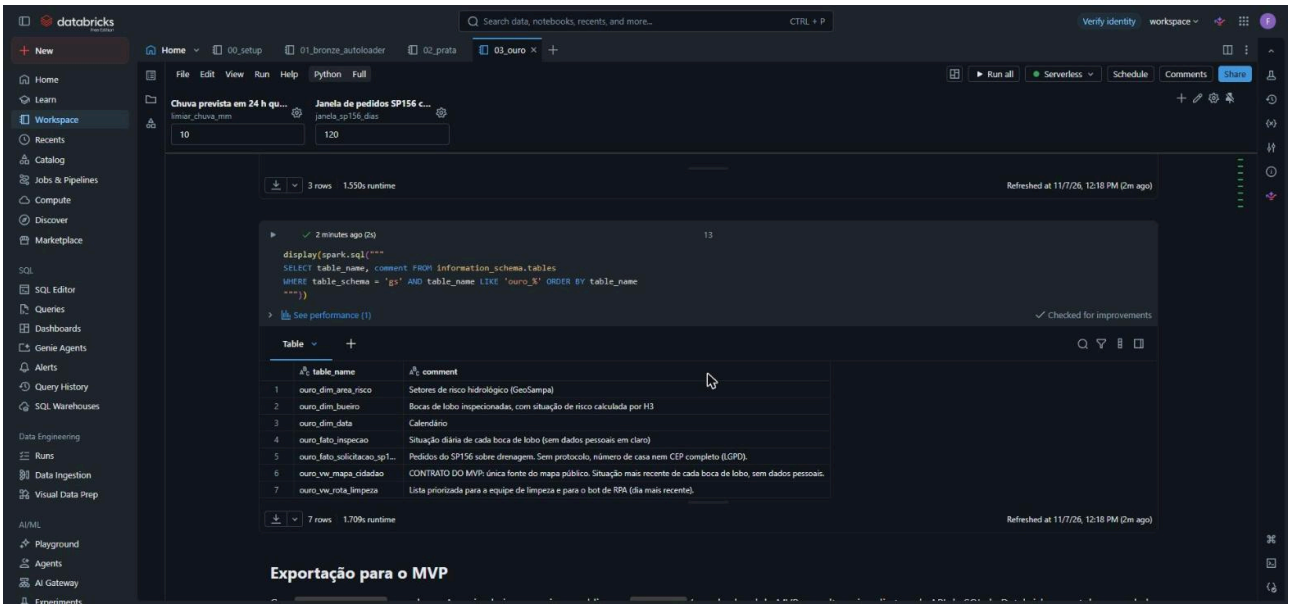


Figura 13 - Tabelas e views da Ouro no schema workspace.gs, com a descrição de cada uma

Requisito 08 · LGPD na Ouro e uso pelo MVP

Dado pessoal	Na Prata (restrita)	Na Ouro
Operador do robô (nome, matrícula, e-mail)	em claro	operador_hash = SHA-256(sal + matrícula + e-mail)
Protocolo do pedido SP156	hash do registro	SHA-256(sal + id)
Número da casa	exato	faixa (ex.: 1800-1899)
CEP	8 dígitos	05409-***
Coordenada do pedido	7 casas	3 casas (~110 m)

O sal é gerado dentro do Databricks (secret scope ou tabela config_lgpd) e passado às consultas como parâmetro nomeado, então não aparece no código nem no texto da query. Contrato com o produto: o mapa público lê SOMENTE a view ouro_vw_mapa_cidadao (id do bueiro, coordenada, rua, status, nível de alerta, chuva prevista, situação de risco), que não tem dado pessoal. O bot de RPA lê ouro_vw_rota_limpeza.

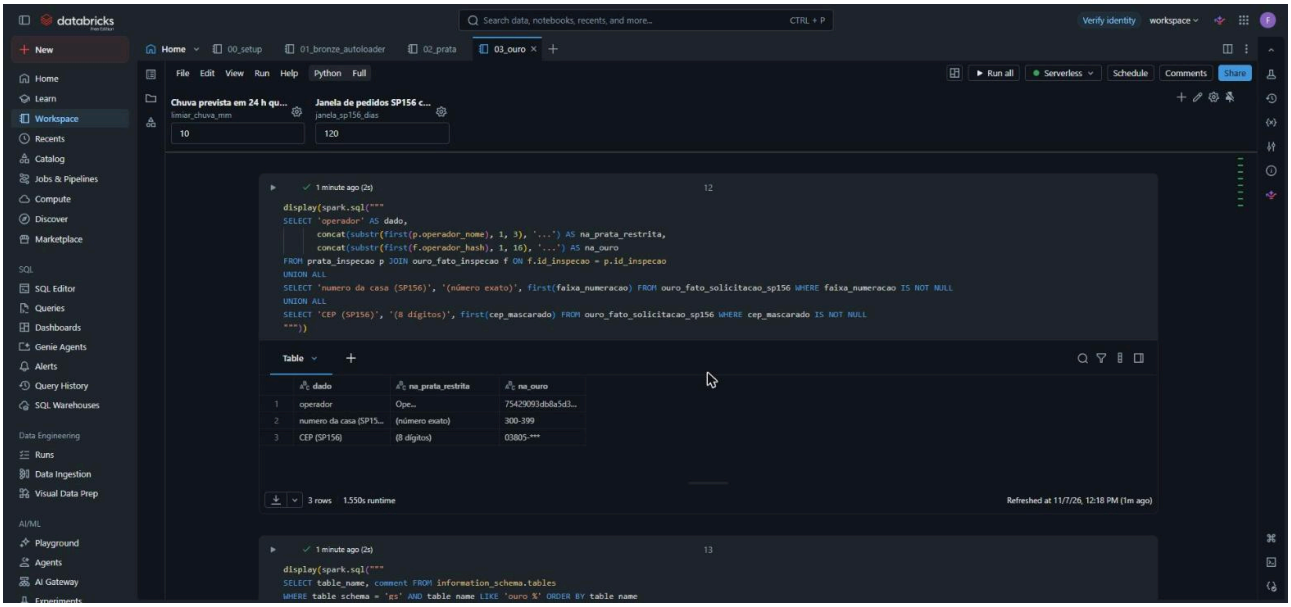


Figura 14 - Notebook 03, prova da LGPD: o que a Prata guarda (restrita) e o que a Ouro expõe (hash, faixa e máscara)

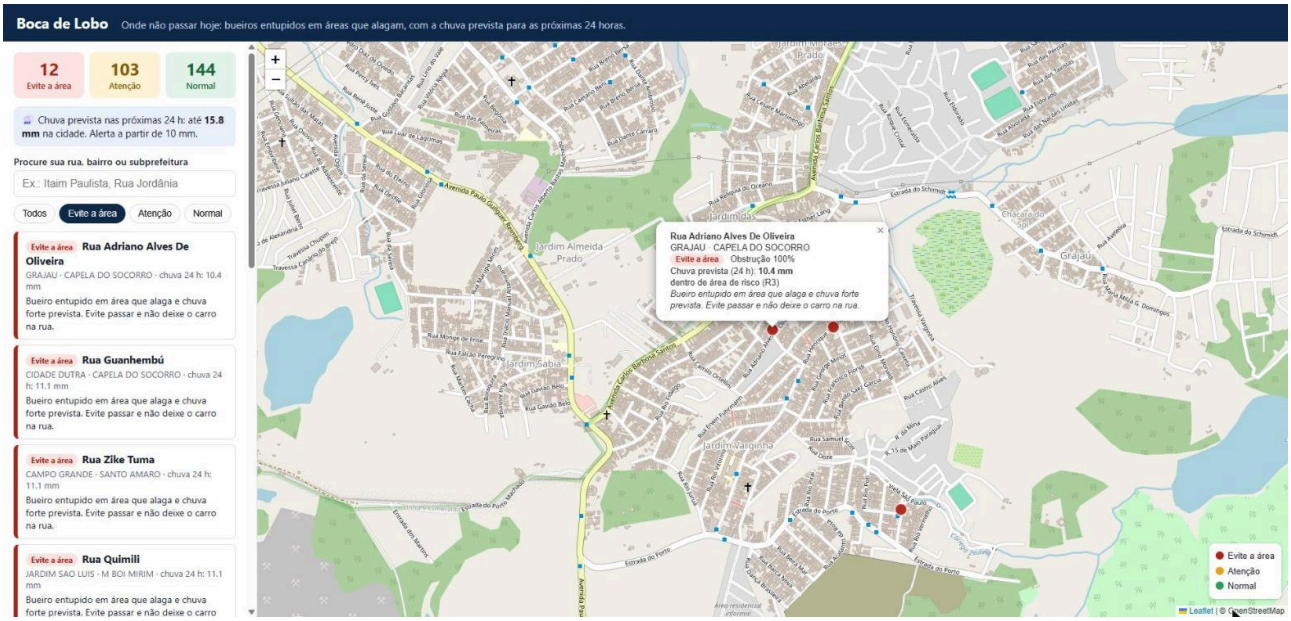


Figura 15 - Tela do MVP lendo o export de ouro_vw_mapa_cidadao (08/11, 259 bocas de lobo): filtro 'Evite a área' e detalhe de um bueiro crítico dentro de área R3

Boca de Lobo

Onde não passar hoje: bueiros entupidos em áreas que alagam, com a chuva prevista para as próximas 24 horas.

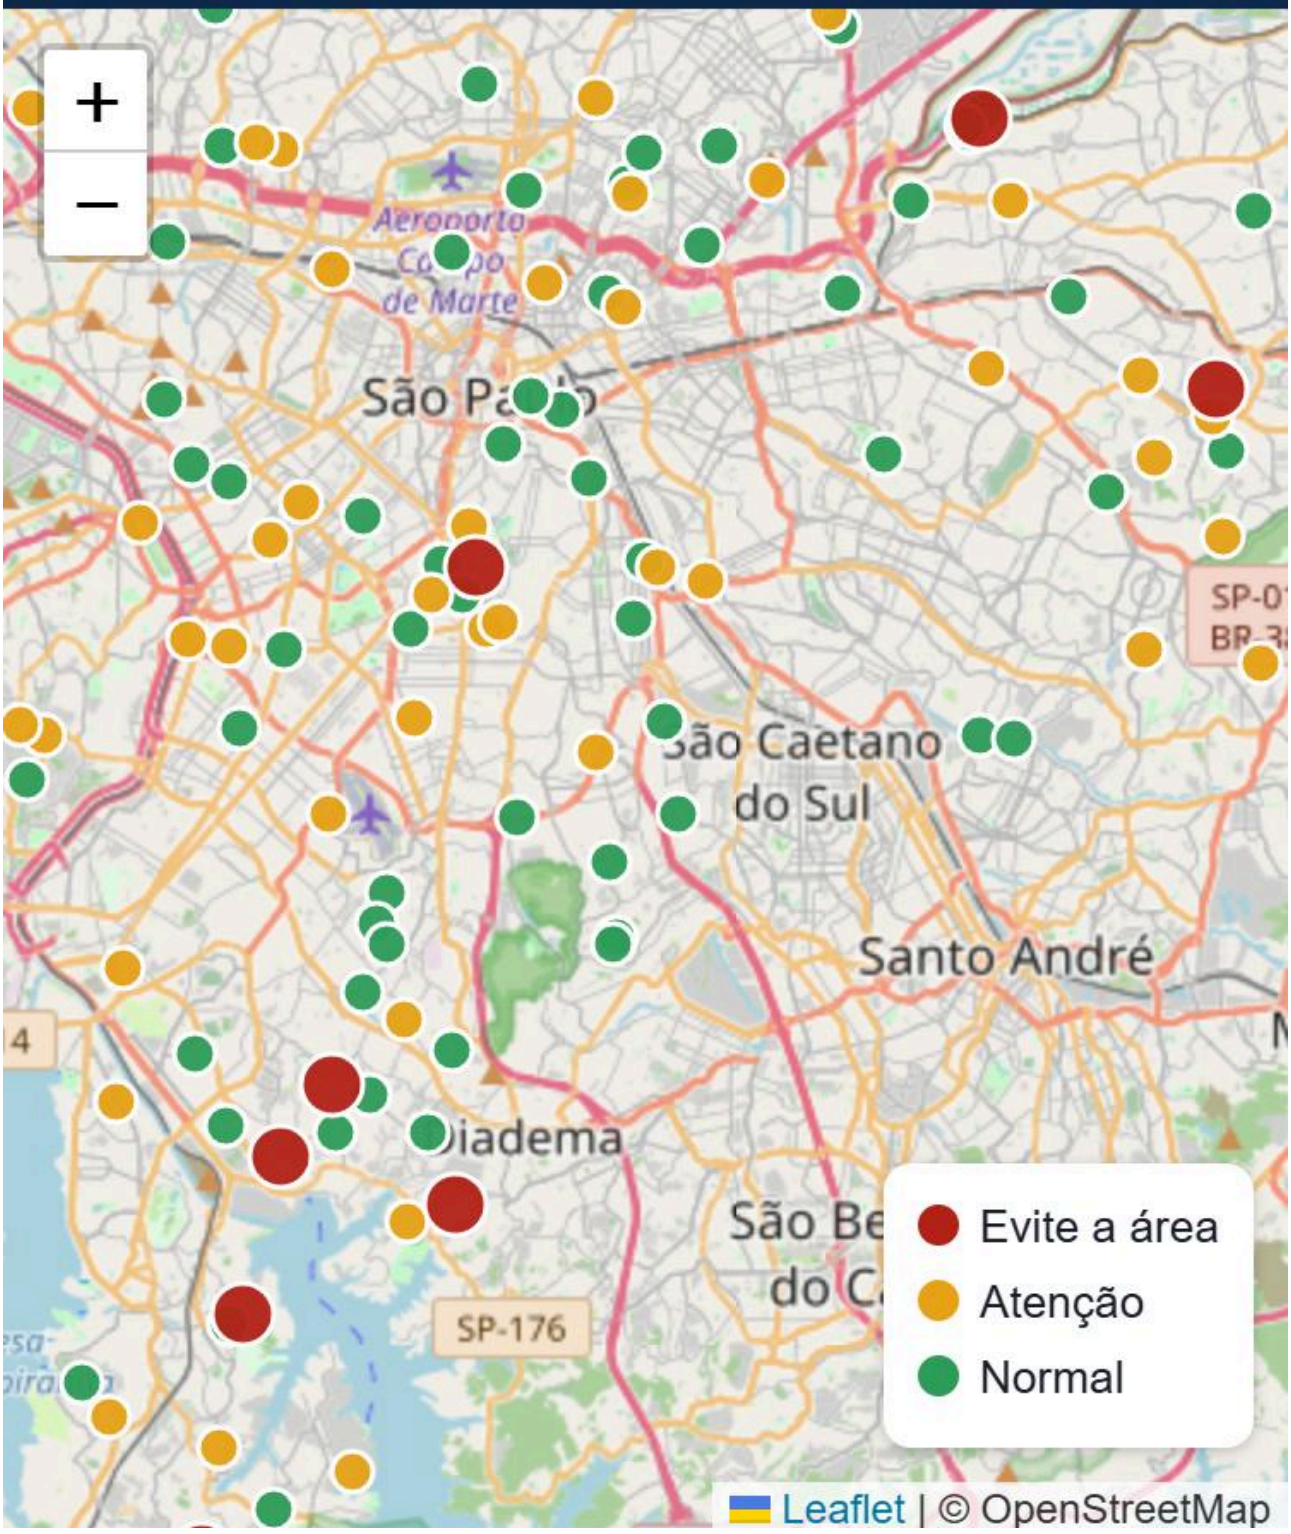




Figura 16 - Tela do MVP no celular: mapa, resumo por nível de alerta e chuva prevista

Requisito 09 · Repositório e README

README com integrantes, ficha técnica, arquitetura, tabela de fontes, passo a passo para reproduzir (Airflow, lotes, Databricks, MVP), mapa requisito → arquivo e LGPD. Estrutura: dags/, databricks/, amostras/, mvp/, scripts/, docs/. Sem chaves, senhas nem dados pessoais reais (.env, chegada/ e lotes/ no .gitignore; amostra do SP156 com número e CEP mascarados).

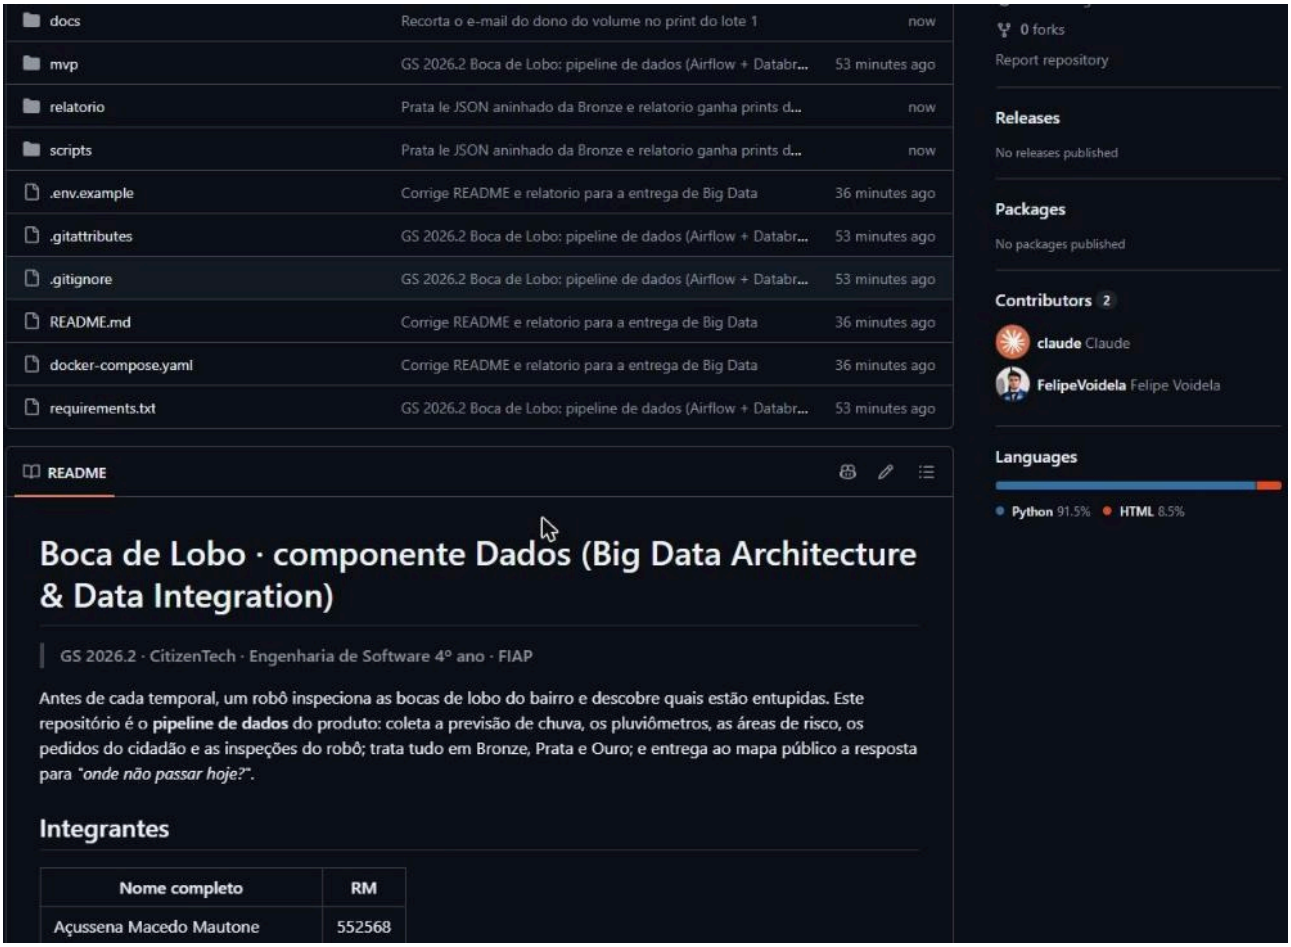


Figura 17 - Repositório público no GitHub com o README renderizado

06 · Prints do Airflow: Graph e Grid com execuções concluídas

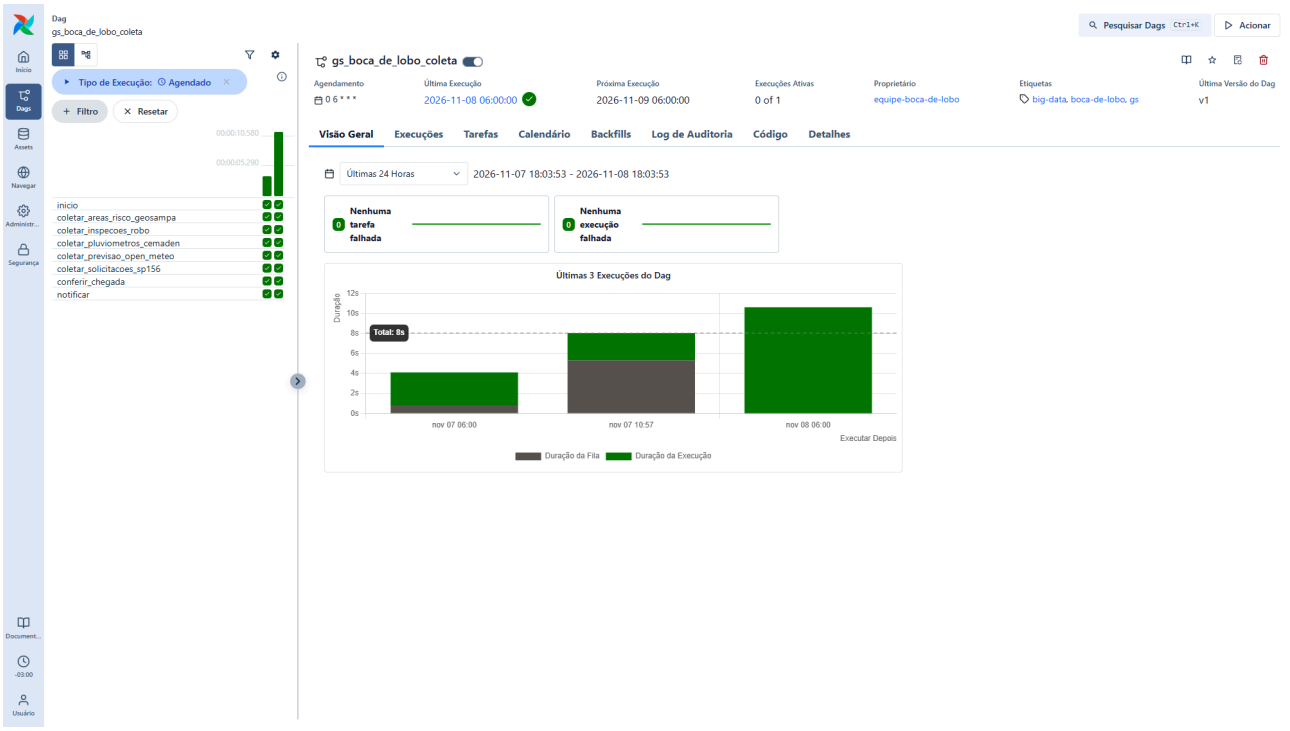


Figura 18 - Visão Geral: grade filtrada por tipo agendado (06h de 07/11 e 08/11, todas as tarefas em verde) e histórico das últimas execuções, nenhuma falha

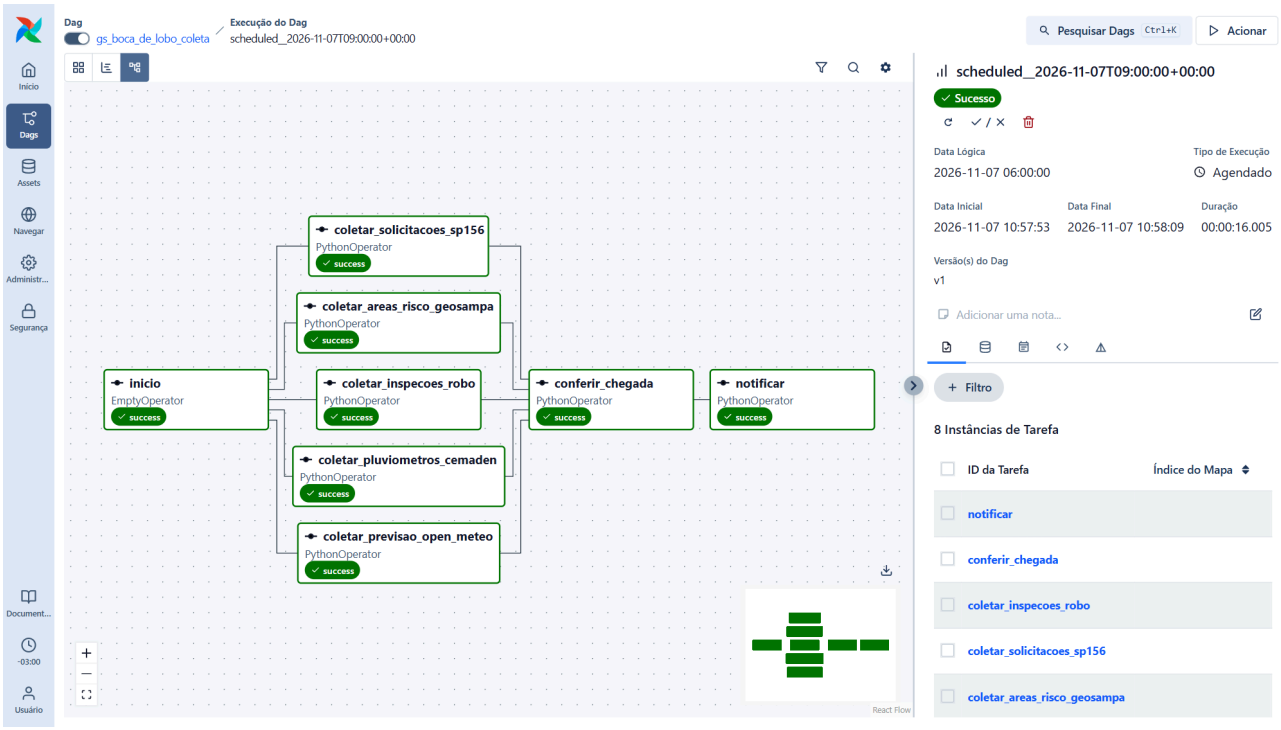


Figura 19 - Visão Graph de uma execução agendada (06h): coletas em paralelo, conferência e notificação

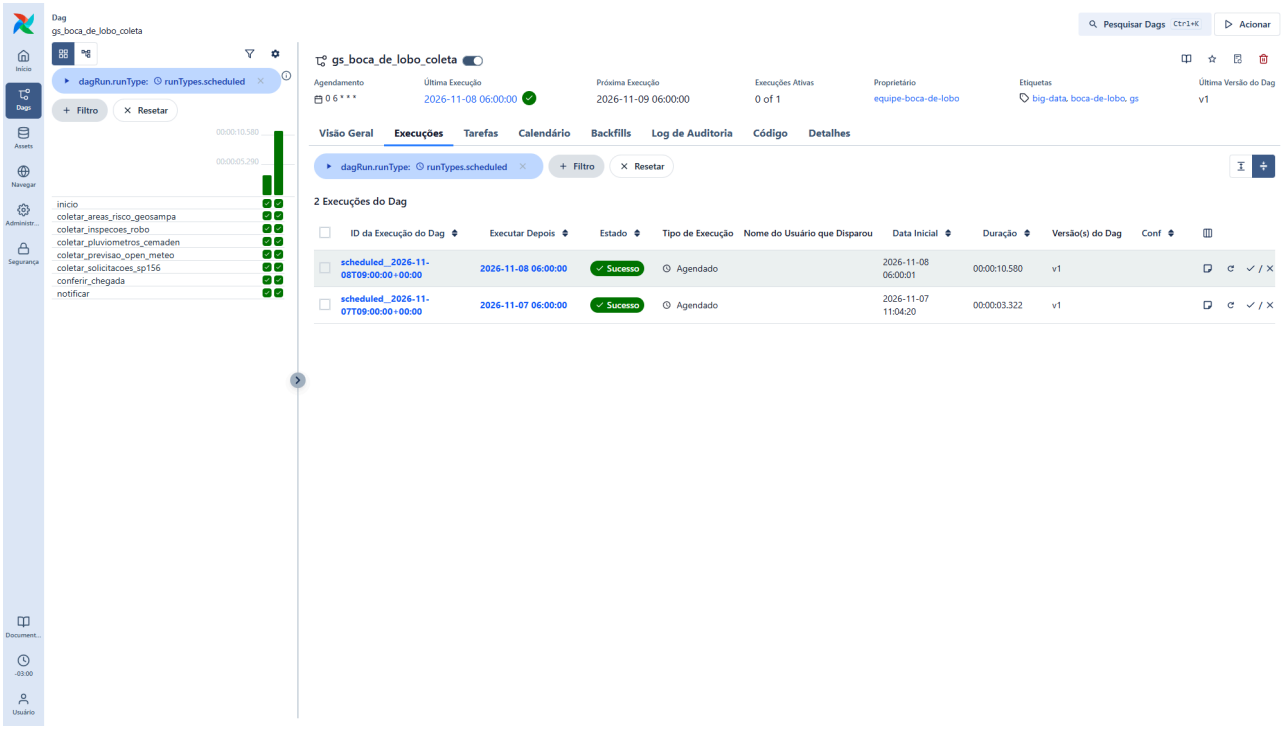


Figura 20 - Lista de execuções agendadas do DAG gs_boca_de_lobo_coleta (07/11 e 08/11, 06h), ambas com sucesso

07 · Contagens da Bronze antes e depois do 2º lote e da 2ª execução

Valores esperados a partir dos arquivos de lotes/ (conferir com o print da tabela controle_cargas):

Tabela	Após lote 1	Após lote 2	2ª execução sem arquivo novo	Linhas inseridas na 2ª execução
bronze_previsao	56	112	112	0
bronze_pluviometros	724	1.448	1.448	0
bronze_areas_risco	793	1.586	1.586	0
bronze_sp156	10.758	21.516	21.516	0
bronze_inspecoes	211	421	421	0

Leitura: no 2º lote cada tabela recebeu só o arquivo novo (o número de arquivos distintos passa de 1 para 2 e as linhas somam as dos dois dias). Na execução seguinte, sem arquivo novo, o checkpoint do Auto Loader não relê nada e a contagem fica igual: não há duplicação. A repetição de conteúdo entre dias (ex.: o mesmo trimestre do SP156) é resolvida na Prata pelo MERGE na chave.

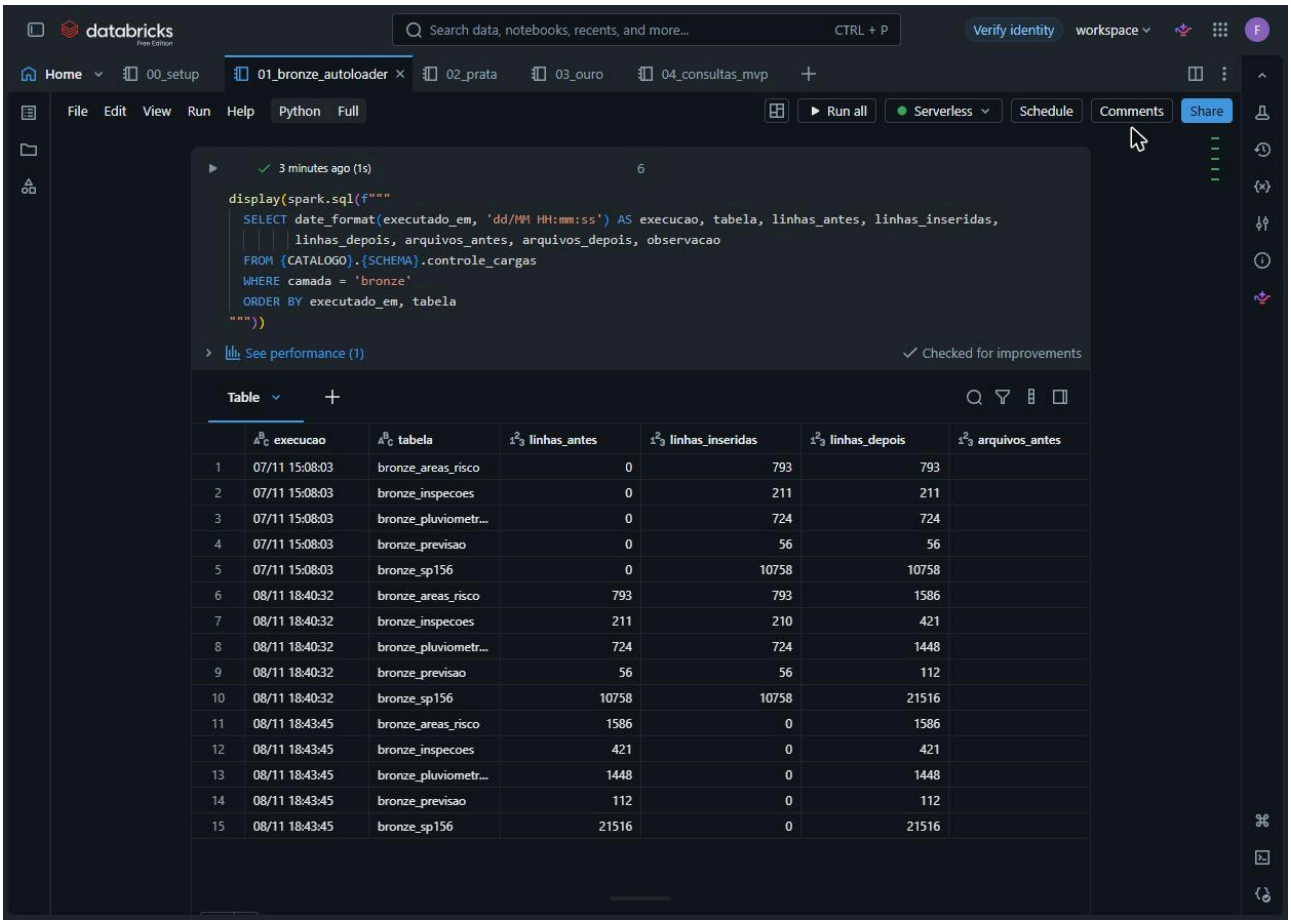


Figura 21 - Notebook 01, histórico das cargas: lote 1, lote 2 e reexecução sem arquivo novo (0 linhas inseridas)

08 · As 5 consultas SQL com resultado e interpretação

Arquivo databricks/04_consultas_mvp.sql. Limiar de chuva: 10 mm em 24 h (variável limiar_mm).

Consulta 1 · IMPACTO: críticos em área de risco com chuva prevista

WITH hoje AS (... ouro_fato_inspecao JOIN ouro_dim_bueiro WHERE data_inspecao = data_ref),
alvo AS (SELECT * FROM hoje WHERE status_ia = 'critico'

AND situacao_risco IN ('dentro','vizinho') AND chuva_prevista_24h_mm >= limiar_mm),
areas AS (SELECT DISTINCT a.id_area, a.qt_moradias, a.pessoas_estimadas FROM alvo JOIN ouro_dim_area_risco a ...)
SELECT bueiros_inspecionados, criticos, criticos_em_area_de_risco, criticos_em_risco_com_chuva_24h, areas_de_risco_afetadas, moradias_nas_areas, pessoas_estimadas ...

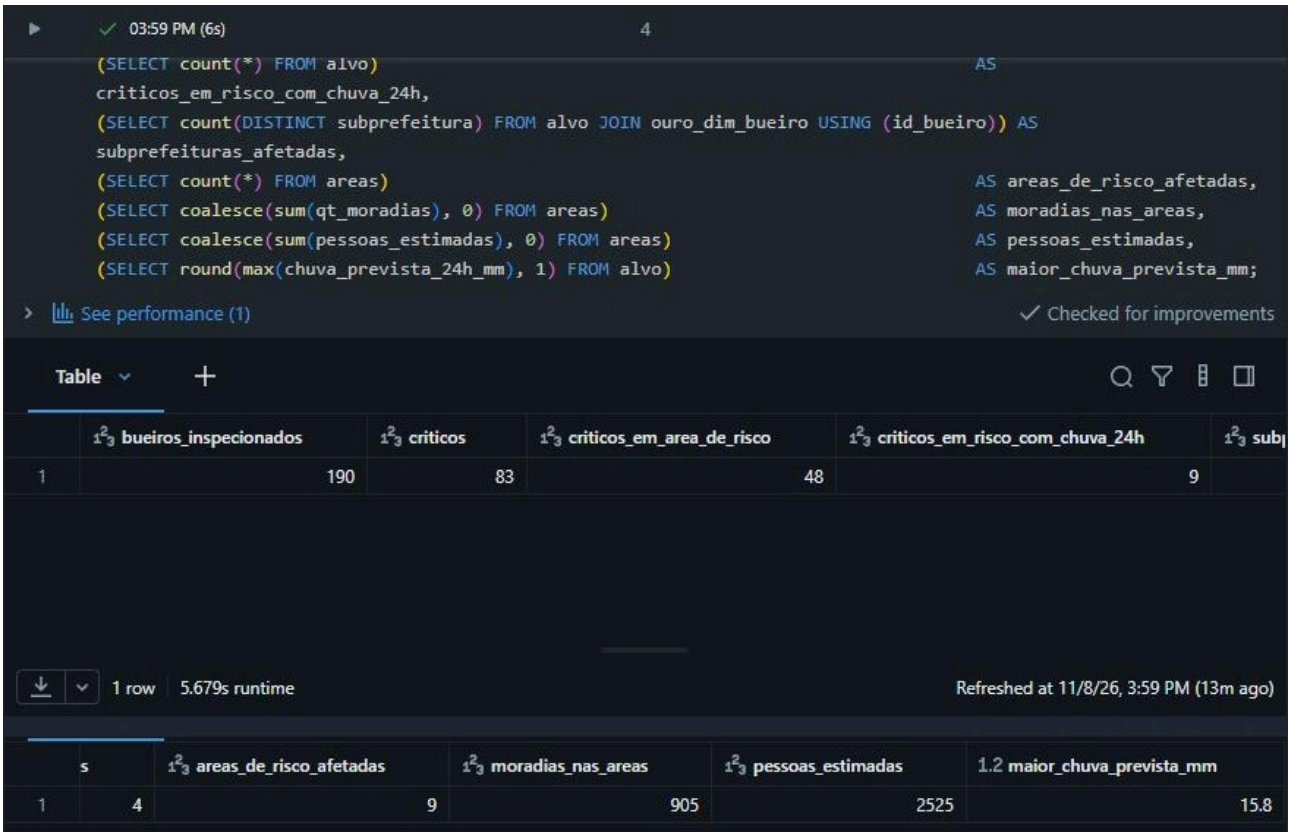


Figura 22 - Resultado da Consulta 1 no notebook 04

Interpretação: Em 08/11/2026 (data de referência, lote 2) o robô inspecionou 190 bocas de lobo: 83 estavam críticas, 48 delas dentro ou ao lado de área de risco hidrológico e 9 nessas condições com chuva prevista de 10 mm ou mais nas próximas 24 h (máximo de 15,8 mm). Essas 9 ficam em 9 setores de risco de 4 subprefeituras, com 905 moradias e cerca de 2.525 pessoas (2,79 moradores por domicílio, Censo 2022). É exatamente a lista que vira alerta 'Evite a área' no mapa e a prioridade zero da equipe de limpeza; os outros 39 críticos em área de risco ficam em 'Atenção' porque a chuva prevista ficou abaixo do limiar.

Consulta 2 · Rota de limpeza priorizada (top 15)

SELECT row_number() OVER (ORDER BY score_prioridade DESC, obstrucao_pct DESC) AS ordem, id_bueiro, logradouro,
subprefeitura, status_ia, obstrucao_pct, situacao_risco, grau_risco, chuva_prevista_24h_mm, score_prioridade
FROM ouro_fato_inspecao f JOIN ouro_dim_bueiro b ... WHERE data_inspecao = data_ref AND status_ia IN ('critico','atencao')

Table

	ordem	id_bueiro	logradouro	distrito	subprefeitura	status_ia
1	1	BL-0022	Rua Calil Jorge Calixto	CAPAO REDONDO	CAMPO LIMPO	critico
2	2	BL-0136	Rua Harry Dannenberg	PARQUE DO CARMO	ITAQUERA	critico
3	3	BL-0027	Rua Domenico Fontana	CAPAO REDONDO	CAMPO LIMPO	critico
4	4	BL-0047	Rua Adriano Alves De Oliveira	GRAJAU	CAPELA DO SOCORRO	critico
5	5	BL-0180	Rua Da Dança Cigana	JARDIM SAO LUIS	M BOI MIRIM	critico
6	6	BL-0052	Rua Guanhembú	CIDADE DUTRA	CAPELA DO SOCORRO	critico
7	7	BL-0171	Rua Ademar Alves Da Nóbrega	JARDIM SAO LUIS	M BOI MIRIM	critico
8	8	BL-0177	Rua Tijuapé	JARDIM ANGELA	M BOI MIRIM	critico
9	9	BL-0239	Rua Zike Tuma	CAMPO GRANDE	SANTO AMARO	critico
10	10	BL-0006	Avenida Do Rio Pequeno	RIO PEQUENO	BUTANTA	critico
11	11	BL-0250	Rua Adão Manoel Da Silva	VILA JACUI	SAO MIGUEL	critico
12	12	BL-0252	Rua Adão Manoel Da Silva	VILA JACUI	SAO MIGUEL	critico
13	13	BL-0165	Travessa Igarapé Primavera	JACANA	JACANA-TREMEMBE	critico
14	14	BL-0251	Rua Adão Manoel Da Silva	VILA JACUI	SAO MIGUEL	critico
15	15	BL-0224	Rua Doutor Antônio Ruggiero Júni...	PIRITUBA	PIRITUBA-JARAGUA	critico

	ɔ	subprefeitura	status_ia	obstrucao_pct	situacao_risco	grau_risco	chuva_pı
1	DONDO	CAMPO LIMPO	critico	100	dentro	R4	
2	O CARMO	ITAQUERA	critico	84.7	dentro	R4	
3	DONDO	CAMPO LIMPO	critico	100	dentro	R3	
4		CAPELA DO SOCORRO	critico	100	dentro	R3	
5	AO LUIS	M BOI MIRIM	critico	100	dentro	R3	
6	UTRA	CAPELA DO SOCORRO	critico	95.8	dentro	R3	
7	AO LUIS	M BOI MIRIM	critico	90	dentro	R3	
8	NGELA	M BOI MIRIM	critico	86.6	dentro	R3	
9	RANDE	SANTO AMARO	critico	80.7	dentro	R3	
10	ENO	BUTANTA	critico	100	dentro	R3	
11	I	SAO MIGUEL	critico	100	dentro	R3	
12	I	SAO MIGUEL	critico	100	dentro	R3	
13		JACANA-TREMEMBE	critico	99.2	dentro	R3	
14	I	SAO MIGUEL	critico	97.3	dentro	R3	
15		PIRITUBA-JARAGUA	critico	95	dentro	R3	

	; grau_risco	chuva_prevista_24h_mm	pedidos_sp156_vizinhanca	score_prioridade	nivel_alerta
1		9.1	6	88	ATENCAO
2		6.8	28	87	ATENCAO
3		9.1	9	82	ATENCAO
4		10.4	21	82	EVITE A AREA
5		9.1	9	82	ATENCAO
6		11.1	5	82	EVITE A AREA
7		9.1	9	82	ATENCAO
8		9.1	12	82	ATENCAO
9		11.1	11	82	EVITE A AREA
10		7.3	5	81	ATENCAO
11		6.1	15	81	ATENCAO
12		6.1	11	81	ATENCAO
13		7.7	8	81	ATENCAO
14		6.1	15	81	ATENCAO
15		6.4	13	81	ATENCAO

Figura 23 - Resultado da Consulta 2 no notebook 04

Interpretação: O topo da rota de 08/11 é a Rua Calil Jorge Calixto (Capão Redondo, Campo Limpo): 100% obstruída, dentro de área R4, score 88, seguida da Rua Harry Dannenberg (Itaquera, R4, score 87, 28 pedidos do SP156 na vizinhança). Depois vêm pontos em áreas R3 de Campo Limpo, Capela do Socorro e M'Boi Mirim (score 82). Os três com 'Evite a área' no top 15 (Grajaú, Cidade Dutra e Campo Grande) são os que somam chuva acima de 10 mm. O score põe na frente quem combina bueiro entupido + área que alaga + chuva + reclamação do cidadão, e não só quem está mais sujo: é a rota que a concessionária paga para receber.

Consulta 3 · Subprefeituras com mais críticos em área de risco

```
SELECT subprefeitura, count(*) inspecionados, count_if(status_ia='critico') criticos, pct_criticos,
count_if(status_ia='critico' AND situacao_risco<>'fora') criticos_em_risco, ...
GROUP BY subprefeitura HAVING count(*) >= 3 ORDER BY criticos_em_risco DESC
```



```
✓ 03:59 PM (3s)                                                    8

SELECT b.subprefeitura,
       count(*)                                                                AS inspecionados,
       count_if(f.status_ia = 'critico')                                       AS criticos,
       round(100 * count_if(f.status_ia = 'critico') / count(*), 1)            AS pct_criticos,
       count_if(f.status_ia = 'critico' AND b.situacao_risco <> 'fora')        AS criticos_em_risco,
       count_if(f.nivel_alerta = 'EVITE A AREA')                               AS pontos_evite_a_area,
       round(avg(f.chuva_prevista_24h_mm), 1)                                  AS chuva_prevista_media_mm,
       sum(f.pedidos_sp156_vizinhanca)                                         AS pedidos_sp156_por_perto
FROM ouro_fato_inspecao f
JOIN ouro_dim_bueiro b ON b.id_bueiro = f.id_bueiro
WHERE f.data_inspecao = data_ref
GROUP BY b.subprefeitura
HAVING count(*) >= 3
ORDER BY criticos_em_risco DESC, pct_criticos DESC
LIMIT 10;

> See performance (1)                                  ✓ Checked for improvements
```

Table

	subprefeitura	inspecionados	criticos	pct_criticos	criticos_em_risco	pont
1	CAMPO LIMPO	21	12	57.1	9	
2	SAO MIGUEL	16	7	43.8	6	
3	CAPELA DO SOCORRO	12	8	66.7	5	
4	M BOI MIRIM	11	7	63.6	5	
5	ITAQUERA	14	6	42.9	4	
6	PIRITUBA-JARAGUA	8	6	75	3	
7	GUAIANASES	6	4	66.7	3	
8	CASA VERDE-LIMAO-CACHOEIRIN...	7	4	57.1	3	
9	CIDADE ADEMAR	3	2	66.7	2	
10	BUTANTA	7	2	28.6	2	

	s	criticos_em_risco	pontos_evite_a_area	chuva_prevista_media_mm	pedidos_sp156_por_perto
1	57.1	9	0	8.4	113
2	43.8	6	0	6.5	272
3	66.7	5	5	10.7	100
4	63.6	5	1	9.5	68
5	42.9	4	0	6.6	107
6	75	3	0	6.9	52
7	66.7	3	0	7	42
8	57.1	3	0	7	152
9	66.7	2	2	14.2	24
10	28.6	2	0	7.6	63

Figura 24 - Resultado da Consulta 3 no notebook 04

Interpretação: Campo Limpo lidera com 9 bueiros críticos em área de risco (12 críticos em 21 inspecionados, 57%), seguida de São Miguel (6), Capela do Socorro e M'Boi Mirim (5 cada). Capela do Socorro concentra 5 dos 12 alertas 'Evite a área' do dia porque é onde a chuva prevista média é maior (10,7 mm). Todas são subprefeituras periféricas, o mesmo território do cidadão do tema: é onde a primeira equipe deve ir. São Miguel também é a que tem mais pedidos do SP156 perto dos bueiros (272).

Consulta 4 · Evolução entre coletas

SELECT d.data, count(*) inspecoes, count_if(status_ia='livre') livres, count_if(status_ia='atencao') atencao, count_if(status_ia='critico') criticos, avg(obstrucao_pct), avg(chuva_prevista_24h_mm), ...

FROM ouro_fato_inspecao f JOIN ouro_dim_data d ON d.data = f.data_inspecao GROUP BY d.data

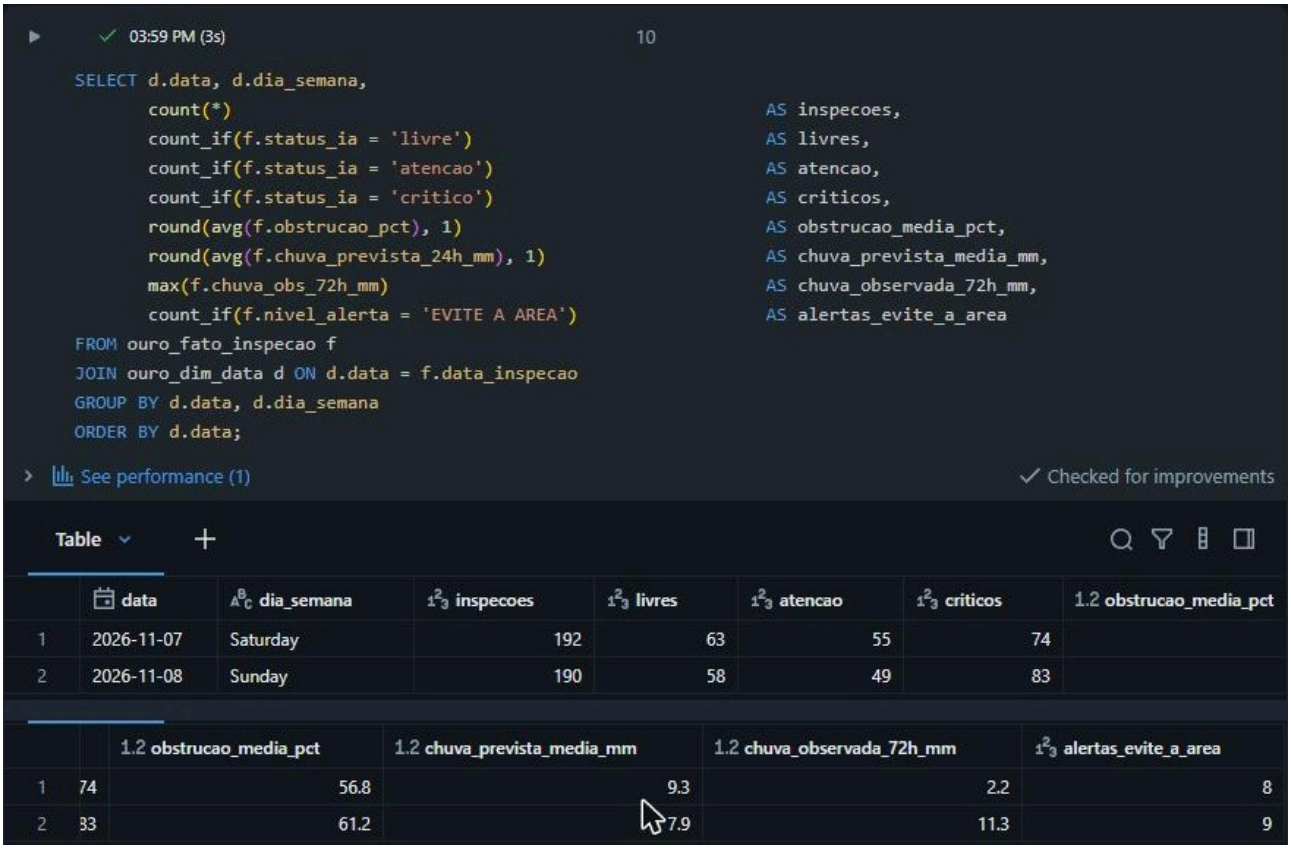


Figura 25 - Resultado da Consulta 4 no notebook 04

Interpretação: De 07/11 para 08/11 os críticos subiram de 74 para 83 (de 192 e 190 inspeções válidas), a obstrução média passou de 56,8% para 61,2% e os alertas 'Evite a área' foram de 8 para 9. A chuva observada nas últimas 72 h subiu de 2,2 mm para 11,3 mm, e a chuva prevista para as 24 h seguintes caiu de 9,3 mm para 7,9 mm: sem limpeza, o lixo acumula de um dia para o outro. Com o pipeline rodando todo dia, a mesma consulta mostra o efeito de cada mutirão e serve de indicador do contrato com a concessionária.

Consulta 5 · Espera do cidadão no SP156 x o que o robô encontra

WITH sp156 AS (SELECT subprefeitura, count(*) pedidos_limpeza_bueiro, percentile_approx(dias_atendimento,0.5),
count_if(status='Aberto') ainda_abertos ... FROM ouro_fato_solicitacao_sp156 WHERE pedido_limpeza_bueiro ...),
robo AS (... criticos_robo por subprefeitura) SELECT ... FROM sp156 LEFT JOIN robo ...

Table

	subprefeitura	pedidos_limpeza_bueiro	mediana_dias_atendimento	media_dias_atendimento
1	SE	369	2	4.1
2	ITAQUERA	325	0	5.3
3	PINHEIROS	319	5	8.4
4	MOOCA	305	0	1.8
5	CAPELA DO SOCORRO	259	1	3.3
6	SAO MIGUEL	255	0	2.2
7	LAPA	242	2	4.7
8	VILA MARIA-VILA GUILHER...	212	3	5.8
9	IPIRANGA	209	3	4.8
10	BUTANTA	207	1	6.6
11	CIDADE ADEMAR	205	1	2.1
12	SANTANA-TUCURUVI	202	4	10.9

12 rows 2.999s runtime Refreshed at 11/8/26, 3:59 PM (12m ago)

	media_dias_atendimento	ainda_abertos	pct_abertos	inspecionados_robo	criticos_robo
1	4.1	125	33.9	2	0
2	5.3	39	12	14	6
3	8.4	100	31.3	6	3
4	1.8	10	3.3	4	2
5	3.3	5	1.9	12	8
6	2.2	2	0.8	16	7
7	4.7	53	21.9	2	0
8	5.8	27	12.7	4	2
9	4.8	1	0.5	6	1
10	6.6	13	6.3	7	2
11	2.1	0	0	3	2
12	10.9	9	4.5	2	0

Figura 26 - Resultado da Consulta 5 no notebook 04

Interpretação: Entre as subprefeituras com mais pedidos de limpeza de bueiro no SP156 (Sé 369, Itaquera 325, Pinheiros 319, Mooca 305), a mediana de atendimento é baixa (0 a 5 dias), mas o percentual que segue aberto varia muito: na Sé 33,9% e em Pinheiros 31,3% dos pedidos ainda estavam abertos na coleta, contra 0,8% em São Miguel e 1,9% em Capela do Socorro. O cruzamento com o robô mostra o outro lado: em São Miguel e Capela do Socorro quase tudo foi fechado no SP156, mas o robô encontrou 7 e 8 bueiros críticos em 08/11. Pedido fechado não significa bueiro limpo, um argumento para a prefeitura contratar a inspeção automática.

09 · Conclusão técnica e link do repositório

O componente Dados coleta todos os dias, às 06h, cinco fontes que juntas respondem à pergunta do tema: onde há bueiro entupido em área que alaga com chuva forte a caminho. O Airflow roda as coletas em paralelo, confere a chegada e avisa quando uma fonte cai. No Databricks, a Bronze é incremental e não duplica (Auto Loader com checkpoint), a Prata aplica 3 regras de qualidade por fonte com contagem e quarentena e faz MERGE pela chave, e a Ouro organiza tudo em estrela, com o cruzamento espacial resolvido por H3 e os dados pessoais protegidos por hash, faixa e máscara.

Decisões que vale destacar: (1) GeoSampa gravado com a geometria como texto GeoJSON, para o Auto Loader não depender de inferir arrays de coordenadas aninhados; (2) try_cast em toda a Prata, porque o serverless roda

em ANSI e o Cemaden manda '-' quando a estação não mede; (3) chave por hash no SP156, que não publica protocolo; (4) o MVP lê só uma view sem dado pessoal, o que torna o contrato com o produto explícito.

Limitações e próximos passos: os pluviômetros do endpoint público do Cemaden não trazem coordenadas (a chuva observada entra como média da capital; com o token da API PED dá para ligar cada estação ao bairro); o SP156 aberto é trimestral; e o robô é simulado até o Maker Lab entregar o carrinho, quando só a função coletar_inspecoes muda.

Repositório público: https://github.com/FelipeVoidela/GS2-2026-Big-Data-Architecture